

Universitat Politècnica de Catalunya

FACULTAT D'INFORMÀTICA DE BARCELONA

# DISTÀNCIES *word2vec*

*Projecte Targetes Gràfiques (TGA)*

Antoni Casas Muñoz  
Pol Martín Garcia

Maig 2020

## Problema a resoldre

El problema a solucionar és la computació de similitud de paraules utilitzant el model *word2vec* de *GloVe* [1] amb la mètrica de similitud de cosinus [2].

*Word2Vec* és una representació densa d'una paraula en un espai vectorial reduït, on la representació manté les analogies semàntiques amb operacions aritmètiques simples, com per exemple  $\text{water} + \text{freeze} \simeq \text{ice}$ , o  $\text{king} - \text{man} + \text{woman} \simeq \text{queen}$ . Això permet operar amb paraules, específicament amb els seus significats, igual que es podria operar amb altres tipus de dades, permetent l'ús d'aquestes representacions per a múltiples tasques.

D'entre totes les operacions que es poden realitzar en un espai vectorial, una de les més senzilles i útils de computar és la distància de dos o més punts en l'espai, així com la cerca dels punts més propers a un altre punt concret d'entre les dades. D'aquesta manera, l'objectiu d'aquest treball és usar aquesta propietat per a poder computar distàncies semàntiques entre paraules, i cercar paraules per proximitat semàntica usant la representació vectorial d'aquestes.

Mentre que per a convertir una paraula a la seva representació densa és tan simple com accedir a un diccionari i extreure el valor, sent un procés només intensiu en espai un cop el diccionari ja ha estat generat, presenten una complicació al fer la conversió de la representació densa (*word2vec*) a la representació esparsa (el vocabulari de l'idioma en què *word2vec* va ser entrenat) aquesta conversió és especialment difícil si s'han dut a terme operacions aritmètiques amb aquesta representació.

La manera de realitzar aquesta conversió és trobar la paraula, o paraules, més properes, i per això s'utilitza la similitud de cosinus. No s'empra la distància euclidiana típica, ja que aquesta mètrica ofereix poc significat en espais amb un gran nombre de dimensions, com és el cas de molts models *word2vec*. En el nostre cas l'espai és de 300 dimensions, és a dir que cada paraula té una representació densa corresponent a un vector de 300 components, també anomenat *embedding*, i per tant la distància euclidiana no seria una mètrica vàlida.

La similitud de cosinus [2] és una mètrica de similitud que és utilitzada per ser fàcil de computar, i oferir valors en el rang de  $[-1, 1]$ , essent 1 el valor que indica absoluta similitud. Aquesta mètrica es computa com amb la següent equació 1. La mètrica no mesura la distància en l'espai, sinó que mesura com són de paral·leles les representacions.

$$\text{cosSim}(\vec{A}, \vec{B}) = \frac{\vec{A} \bullet \vec{B}}{|\vec{A}| \cdot |\vec{B}|} \quad (1)$$

## Canvis al model

Per a la implementació de l'algoritme, primer hem obtingut el model de *word2vec* de *GloVe* [1], i l'hem modificat ordenant alfabèticament les paraules i afegint les normes de cada representació densa al model propi, d'aquesta manera no és necessari computar la norma en cada operació de similitud. També, s'ha fet una millora en implementacions consecutives, on el model són dos fitxers, un amb les paraules ordenades, i un altre fitxer binari amb les representacions denses emmagatzemades. El model llavors està format per unes  $2.2 \cdot 10^6$  paraules (concretament 2196016 paraules), on cada paraula és una línia al fitxer, primer la paraula, després la norma, i finalment els 300 valors de la representació densa.

És adient mencionar que cadascuna de les components de les representacions denses de les paraules es troba en el rang  $[-1, 1]$ , d'aquesta manera s'obté una millora de precisió en emmagatzemar i operar amb nombres de coma flotant.

## Ús del software

Per poder compilar el codi font s'ha creat un sistema de **CMake**. D'aquesta manera es pot compilar el programa independentment de la plataforma.

És necessari, per al correcte funcionament de la configuració del *makefile*, que **CMake** tingui la referència del compilador de CUDA prèviament (usualment en un arxiu **CMakeCUDACompiler.cmake**); sinó s'haurà d'emmagatzemar a l'entrada **CMAKE\_CUDA\_COMPILER** el *path* del compilador de CUDA.

Actualment el projecte està configurat per a usar memòria *pinned* per defecte. De no voler emmagatzemar les dades en aquest tipus de memòria cal modificar l'arxiu **CMakeLists.txt** i descomentar la línia 7, que activa la definició de compilació **NOT\_PINNED\_MEMORY**.

Per altra banda, el projecte també està configurat per generar codi per arquitectura Turing (*sm\_75*). De voler generar codi per a una altra arquitectura cal modificar la línia 75 de l'arxiu **CMakeLists.txt** adientment.

Un cop el projecte ja es troba compilat, hi ha dues maneres d'executar el programa resultant.

- Dades en arxiu TXT. Passar un sol paràmetre, corresponent amb el *path* d'un arxiu de text amb les paraules, normes i *embeddings*. El fitxer usat per nosaltres es pot obtenir de <https://workbench.ddns.net/nextcloud/index.php/s/mcx38NDMMzmDgQ>.
- Paraules en TXT, i binari amb dades. Passar dos paràmetres. Un primer *path* a un arxiu amb el llistat de paraules (*keys*), i un segon *path* a un arxiu binari amb les normes i els *embeddings* preprocessats (*values*). Els arxius són respectivament <https://workbench.ddns.net/nextcloud/index.php/s/qtkbG6Nxx2wWLnF> i <https://workbench.ddns.net/nextcloud/index.php/s/6FAjH6QP6sYzf9c>.

La diferència entre les dues entrades, és que la segona és notablement més ràpida que la primera ja que no necessita dur a terme el *parsing* dels nombres en coma flotant.

Amb les dades carregades, s'imprimeixen per consola els temps i altra informació interessant sobre aquesta etapa, i s'inicia l'entrada de dades per a dur a terme computacions. Aquesta entrada ha de consistir d'una paraula arbitrària i d'un valor 0, 1. El valor identifica si s'ha d'executar també el còmput corresponent en CPU.

Per cada entrada de les anteriors, és dura a terme una cerca de la paraula introduïda en la base de dades. Si aquesta hi és, és procedirà a computar i escriure per consola les 10 paraules sintàcticament més semblants en la codificació *word2vec*, així com diverses mètriques per avaluar l'eficiència de la consulta.

El programa acaba quan es tanca la *pipe* d'entrada.

## Implementació

Hi ha dues versions correctament implementades del projecte, amb resultats finals equivalents.

Aquestes versions també són equivalents al codi seqüencial, trobat al fitxer *main.cpp* en la funció **sequentialSearch()**. Aquesta, donat un vector d'*embeddings*, l'índex d'un d'aquests, i un nombre *N*, troba d'entre tots els *embeddings* del vector els *N* més semblants a l'*embedding* identificat per l'índex.

## Algoritme

Qualsevol dels algorismes implementats per a solucionar aquest problema es basen en 3 parts.

1. Trobar la paraula en el vector d'*embeddings*. Aquest pas sempre es du a terme amb una cerca binària en CPU, per tant no el discutirem en aquest document.
2. Dur a terme el còmput de les distàncies de cosinus (o similituds de cosinus) entre tots els *embeddings* i l'*embedding* de la paraula cercada.
3. Filtrar els resultats, i escollir les N paraules més semblants (amb major similitud) a la paraula cercada amb les dades calculades, de manera ordenada.

Els punts 2 i 3, es troben tan implementats per a CPU, a *main.cpp*, com per GPU, a *kernel.cu*.

## Càlcul de similituds

El càlcul de les distàncies o similituds es du a terme a GPU pel kernel `DotProduct()`, el qual calcula el producte escalar amb cadascun dels *embeddings*, i posteriorment en divideix el resultat pel producte de normes.

Això es du a terme movent el *embeddings* de la paraula cercada a memòria *shared*, i posteriorment l'usen tots els *threads* del bloc per a dur a terme el producte escalar amb un altre *embedding*.

D'aquesta manera cada *thread* computa una sola similitud.

## Filtrat i ordenació

El filtrat per GPU requereix conèixer les N paraules amb una major similitud. Per a això s'ha dividit el còmput d'aquest procés en dues funcions.

La primera, `FirstMerge()`, divideix el vector de similituds resultants en trossos de N elements, els quals són ordenats usant ordenació per inserció donat que N sempre serà un nombre petit. L'ordenació es du a terme *on-place*, de manera que es reutilitza la mateixa memòria per emmagatzemar el resultat.

D'aquesta forma, obtenim el vector de similituds en trossos de N elements internament ordenats. Evidentment, a part d'aquest vector de similituds s'emmagatzema un vector de índex a les paraules originals, per no perdre la relació entre valor de similitud i la respectiva paraula.

Seguida i finalment la funció `BotchedMergeSort()` aprofita els segments ordenats per a dur a terme l'ordenació en una reducció del problema. Cada *thread* compara dos dels pedaços de N elements preordenats en un de sol.

Aquesta funció redueix el nombre de similituds a comparar a la meitat per cada crida, i es va usant fins que només resta un sol vector de N elements, el qual identifica les N paraules amb major similitud.

## Canvis de versió

Les millores en la segona versió del programa són separables en canvis en el codi del kernel, i en carrega de les dades a memòria.

Pel que fa al kernel, s'ha reduït l'espai de memòria reservat, utilitzant memòria local de cada *thread* per emmagatzemar l'ordenació temporal en el mètode `BotchedMergeSort()`. A més, s'ha afegit control d'errors complet.

Per altra banda, s'ha millorat substancialment la càrrega a memòria separant l'arxiu d'input en dos, un que conté els *strings* de les paraules, i un altre que conté les normes i els *embeddings* ja en binari, per estalviar la conversió a float en temps d'execució, a més que el fitxer és de menor mida en binari.

Finalment, s'ha afegit l'opció d'usar o no memòria *pinned* segons una *flag* de compilació.

## Resultats

Els resultats han sigut obtinguts en una màquina amb una GTX 2060 SUPER com a targeta gràfica, utilitzant un slot x16 PCIe 3.0, Intel I5-9600K com a CPU, i els models guardats en una NVME, Samsung 970 EVO, amb suficient RAM DDR4 per a no observar *thrashing*. El sistema no té límits a *pinned memory*, per tant totes les execucions s'han fet utilitzant *pinned memory*.

En la implementació seqüencial, com a mitjana de 10 execucions, el temps d'execució d'una cerca és de 2425.9ms, amb un error estàndard de 7.91ms, això significa que ha calculat 2196016 distàncies a una velocitat de 905.2 distàncies calculades per ms.

En l'última implementació de CUDA, com a mitjana de 10 execucions, el temps d'execució d'una cerca és de 36.8ms, amb un error estàndard de 1.58ms, això significa que ha calculat 2196016 distàncies a una velocitat de 59674.3 distàncies calculades per ms. De els 3 kernels (`DotProduct()`, `FirstMerge()` i `BotchedMergeSort()`), `DotProduct()` ocupa uns 22ms, `FirstMerge()` 0.8ms, i `BotchedMergeSort()` 1.3ms, la resta de temps essent overhead, per tant `FirstMerge()` i `BotchedMergeSort()` es poden considerar negligibles comparat amb `DotProduct()`.

	CPU	GPU
ring	2405ms	35ms
key	2397ms	46ms
key	2410ms	35ms
key	2403ms	46ms
ring	2436ms	31ms
king	2468ms	35ms
king	2454ms	35ms
ring	2419ms	35ms
barca	2414ms	35ms
messi	2453ms	35ms

	Speedup respecte anterior	Speedup respecte CPU
Primera implementació		??
Segona implementació	??	65.92

## Millors descartades

## Referències

- [1] “Glove: Global vectors for word representation.” <https://nlp.stanford.edu/projects/glove/>. (Accessed on 05/06/2020).
- [2] “Cosine similarity - wikipedia.” [https://en.wikipedia.org/wiki/Cosine\\_similarity](https://en.wikipedia.org/wiki/Cosine_similarity). (Accessed on 05/06/2020).